

Araştırma Makalesi

Tümlev İmge Gösterim Yöntemleri ile Hesapsal Karmaşıklık Düşürülmesi

Tolga Tunçel^a

^aBilgisayar Mühendisliği, Fen Bilimleri Enstitüsü, Kocaeli, 41004, Türkiye

Özet

Günümüzde teknolojinin ilerlemesi ile birlikte üretimde performans önemli bir hale gelmiştir. Kullanıcı cepheden bakılacak olursa her çıkan yeni ürün veya çıkan bir ürünün bir önceki sürümüne göre performans artışı beklenmektedir. Performansın ana kriterlerinden biri ise hızdır. Geçmişten günümüze çeşitli algoritmalar ve metotlar ile hız konusunda çalışmalar yapılmıştır. Bu çalışmada hız ve performans konusunda iyileştirme için düşük işlem yükü sağlayan tümlev imge gösterim yöntemi ile bölge kovaryansı hesaplanmasının nesne tespiti ve doku sınıflandırılması üzerinde etkisi gösterilmiştir.

Anahtar Kelimeler: Tümlev İmge Gösterim, Bölge Kovaryansı, Nesne Tespiti, Doku Sınıflandırılması

Abstract

Today, with the advancement of technology, performance in production has become important. From the front of the user, every new product or an increase in performance over a previous version of a product is expected. One of the main criteria of performance is speed. Various algorithms and methods have been studied in terms of speed from past to present. In this study, the effect of calculating region covariance on object detection and tissue classification was shown by the method of integral image representation, which provides a low processing load for improvement in speed and performance.

Keywords: Integral Image, Region Covariance, Object Detection, Texture Classification

1. Giriş

Günümüzde özellik seçimi, algılama ve sınıflandırma sorunları için en önemli adımlardan biridir. İyi özellikler ayırt edici, güçlü ve hesaplanması kolay olmalıdır. Tanıma ile izleme gibi çeşitli görevler için verimli algoritmalar gerekmektedir [1]. Verimli algoritmalar, verimli metotları, verimli metotlar ise verimli uygulamaları doğurmuştur.

Renk, gradyan ve filtre yanıtları gibi çeşitli resim istatistiklerinin ham piksel değerleri, resim özellikleri için en basit seçimdir ve bilgisayar görüşünde uzun yıllar boyunca kullanılmıştır [2]. Fakat, bu özellikler aydınlatma değişiklikleri ve rijit olmayan hareketlerin varlığında güçlü değildir.

Verimli eşleme algoritmaları yüksek boyutlu gösterimle sınırlanmıştır. Sınıflandırma ve izleme için ise düşük boyutlu gösterimler de kullanılmıştır [3]. Sınıflandırma ve izlemenin yanı sıra; doku görüntüsü, eşleştirme ve bilgisayar görüşü alanındaki diğer sorunlar için

histogramlar da kullanılmıştır.

Integral resim fikri ilk olarak Haar benzeri özelliklerin hızlı hesaplanması için kullanılmıştır [4]. Basamaklı AdaBoost sınıflandırıcıyla birleştirildiğinde, yüz tanıma sorunu için üstün performanslar önceki çalışmalarda bildirilmiştir, ancak algoritma nesne sınıflandırıcılarını öğrenmek için uzun bir eğitim süresi gerektirmektedir.

Bu çalışma ile 2 farklı katkı sağlanmıştır. İlk olarak, bölge tanımlayıcısı olarak, ilgilenilen bir bölgede hesaplanan çeşitli resim istatistiklerinin kovaryansının kullanılması önerilmiştir. Görüntü istatistiklerinin ortak dağılımı yerine kovaryansın kullanılması boyutu daha küçültmüştür. Bu çalışmada integral görüntüleri kullanarak kovaryans hesaplamasının hızlı bir yolu sunulmuştur ve hesaplama maliyeti bölgenin büyüklüğünden bağımsızdır.

İkinci olarak Bu çalışmada ikinci olarak, kovaryans özelliklerini kullanarak nesne algılama ve doku sınıflandırma için yeni algoritmalar sunulmuştur.

Bölüm 2.1’de kovaryans özellikleri ve integral resim fikri kullanılarak bölge kovaryansının hızlı hesaplanması açıklanmıştır. Bölüm 2.2’de nesne algılama problemi, bölüm 2.3’de doku sınıflandırma problem üzerinde durulmuştur.

* Sorumlu Yazar Tel.: +90 262 3032279;

fax: +90 262 3032203.

E-mail adresi: mhsoz@kocaeli.edu.tr

2. Malzeme ve Yöntem

2.1. Bölge Tanımlayıcı Olarak Kovaryans

Bir boyutlu yoğunluk olsun ya da 3B renkli resimdir. Bu metot ayrıca diğer türdeki resimleri genelleştirmektedir (Ör: Kızılötesi)

$$9F(x, y) = \varphi(I, x, y) \quad (1)$$

F de Genişlik (Width) x Yükseklik (Height) x d I dan çıkarılan boyutsal özellik resmidir. φ herhangi bir haritalamadır (Ör: yoğunluk, renk, gradyan, filtre cevabı vb.). Verilen bir dikdörtgen alan (Region = R) için $R \subset F$ dir.

$$17 C_R = \frac{1}{n-1} + \sum_{k=1}^n ((z_k - \mu)(z_k - \mu)^T) \quad (2)$$

$\{z_k\}_{k=1..n}$, R'nin içindeki boyutsal özellik noktalarıdır. R, d x d den oluşan bir kovaryans matrisidir. μ , bu noktaların ortalamasıdır.

Kovaryans matrisinin bölge tanımlayıcısı olarak kullanılmasının pek çok avantajı vardır. Bir bölgeden çıkarılan tek bir kovaryans matrisi genellikle bölgenin farklı görünüm ve pozunun eşleştirilmesi için yeterlidir.

Kovaryans matrisi, ilişkili olabilecek birden fazla özelliği birleştirmek için doğal bir yöntem sunmaktadır. Kovaryans matrisinin diyagonal girişleri, her bir özelliğin varyansını ve diyagonal olmayan girişlerin korelasyonlarını temsil etmektedir. Bireysel örnekleri bozan gürültü, kovaryans hesaplaması sırasında büyük ölçüde ortalama bir filtreyle filtrelendir.

Kovaryans matrisleri (C_R nin yalnızca $(d^2+d)/2$ farklı değeri olduğundan yani simetriden dolayı) diğer bölge tanımlayıcılarına kıyasla düşük boyutludur. Oysa aynı bölgeyi ham değerlerle temsil etmiş olsaydık $n \times d$ adet boyuta ihtiyacımız olurdu. Aynı şekilde yukarıdaki durum için; ortak özellik histogramları kullanılsaydı b^d adet boyuta ihtiyaç olurdu (burada b, her özellik için kullanılan histogram kutularının sayısıdır). Örnek bir bölge olarak R göz önüne alındığında, R nin kovaryansı (C_R), düzen ve nokta sayılarına ilişkin bir bilgi içermemektedir.

Bu durum, farklı resimlerdeki bölgeler üzerinde belirli bir ölçek ve dönme değişmezliği anlamına gelmektedir. Bununla birlikte, x ve y'ye göre gradyan normu gibi noktaların oryantasyonunu içeren bilgiler sunulursa, kovaryans tanımlayıcısı artık rotasyonel olarak değişmezdir. Aynı argüman ölçek ve aydınlatma için de geçerlidir. Dönme ve aydınlatmaya bağlı istatistikler tanıma ve sınıflandırma amacıyla önemlidir. Bunları Bölüm 2.2 ve 2.3'te bunlar kullanılmıştır.

2.1.1 Kovaryans Matrislerinde Mesafe Ölçümü

Öklid boşlukta kovaryans matrisleri hata vermezler. Örneğin boşuk, negatif ölçekleyicilerle çarpılması halinde kapanmaz.

Yaygın makine öğrenme yöntemlerinin çoğu, Öklid uzayları üzerinde çalışır ve bu nedenle yukarıda bahsedilen özellikler için uygun değildir. Aşağıdaki bölümlerde kullanılacak en yakın komşu algoritması, yalnızca özellik noktaları arasındaki mesafeleri hesaplamının bir yolunu gerektirmektedir [5].

Bu çalışmada iki kovaryans matrisinin farklılığını ölçmek için, uzaklık ölçümü kullanılmaktadır.

$$67p(C_1, C_2) = \sqrt{\sum_{i=1}^n \ln^2 \lambda_i(C_1, C_2)} \quad (3)$$

$\{\lambda_i(C_1, C_2)\}_{i=1..n}$, C_1 ve C_2 nin genelleştirilmiş özdeğerleridir. Bu değerler, aşağıdaki hesaplama ile elde edilmektedir.

$$72 \lambda_i C_1 x_i - C_2 x_i = 0 \quad i = 1 \dots d$$

$$74 x_i \neq 0$$

Uzaklık ölçüsü ρ , pozitif ve kesin simetrik matrisler (C_1 ve C_2) için metrik aksiyomları karşılamaktadır.

$$79 1. \rho(C_1, C_2) \geq 0 \text{ and } \rho(C_1, C_2) = 0 \text{ only if } C_1 = C_2$$

$$80 2. \rho(C_1, C_2) = \rho(C_2, C_1)$$

$$81 3. \rho(C_1, C_2) + \rho(C_1, C_3) \geq \rho(C_2, C_3).$$

Genelleştirilmiş özdeğerler, sayısal yöntemler kullanılarak $O(d^3)$ aritmetik işlemleriyle hesaplanabilir ve uzaklık hesaplaması için ek bir d logaritma işlemi gerekir, bu genellikle d ile üssel olarak büyüyen iki histogramı karşılaştırmaktan daha hızlıdır [6].

2.1.2 Hızlı Kovaryans Hesaplama İçin İntegral Resmi

İntegral resimler, bölge toplamalarının hızlı hesaplanması için kullanılan ara resim sunumlarıdır [7]. İntegral resmin her pikseli, görüntünün sol üst köşesi ve ilgililenen piksel tarafından sınırlanan dikdörtgenin içindeki tüm piksellerin toplamıdır. Bir yoğunluk resmi için "I", bütünsel integral resmi olarak aşağıdaki gibi tanımlanır:

$$101 \text{Integral Image } (x', y') = \sum_{x < x', y < y'} I(x, y) \quad (4)$$

I, integral resmi x, y, x', y' resim üzerindeki koordinat noktalarıdır.

Bu gösterimi kullanarak, herhangi bir dikdörtgen bölge toplamı kısa bir sürede hesaplanmaktadır. İntegral resimler, bölge histogramlarının hızlı hesaplanması için daha yüksek boyutlara genişletilmiştir [8].

Bu çalışmada ayrıca bölge kovaryanslarının hızlı hesaplanmasına benzer bir fikir ortaya atılmıştır.

Buna göre kovaryans matrisinin (i, j) -nci elemanını aşağıdaki gibi yazılabilmektedir:

$$C_R(i, j) = \frac{1}{n-1} \sum_{k=1}^n ((z_k(i) - \mu(i))(z_k(j) - \mu(j))) \quad (5)$$

Ortalamanın genişletilmesi ve yazılan terimlerin yeniden düzenlenmesi ile:

$$C_R(i, j) = \frac{1}{n-1} \sum_{k=1}^n \left((z_k(i)z_k(j)) - \frac{1}{n} \sum_{k=1}^n z_k(i) \sum_{k=1}^n z_k(j) \right) \quad (6)$$

Şeklinde ifade edilebilir.

Belirli bir dikdörtgen bölgedeki (R) kovaryansını bulmak için, her bir özellik boyutunun toplamı ile, $z(i)_{i=1 \dots n}$ eşitliğinde olduğu gibi, iki özellik boyutunun çarpımının toplamını da hesaplamamız gerekir. $z(i) z(j)_{i,j=1 \dots n}$ özellik boyutlarının her biri için $d + d^2$ integral resimleri ve herhangi iki özellik boyutunun çarpımını oluştururuz, $z(i) z(j)$.

P, integral resimlerin $W \times H \times d$ tensörü (Tensor) olsun. Bu durumda:

$$P(x', y', i) = \sum_{x < x', y < y'} F(x, y, i) \quad i=1 \dots d \quad (7)$$

ve Q da, ikinci mertebeden görüntülerin $W \times H \times d \times d$ tensörü olursa:

$$Q(x', y', i, j) = \sum_{x < x', y < y'} F(x, y, i) F(x, y, j) \quad i, j=1 \dots d \quad (8)$$

İntegral resim hedef resim üzerinde tek seferde hesaplanabilmektedir. Mevcut notasyonda, $p_{x,y}$, d boyutlu vektör ve $Q_{x,y}$, $d \times d$ boyutlu matristir [9]. Bu durumda:

$$P_{x,y} = [P(x,y,1) \dots P(x,y,d)]^T \quad (9)$$

$$Q_{x,y} = \begin{pmatrix} Q(x,y,1,1) & \dots & \dots & Q(x,y,1,d) \\ \vdots & & & \vdots \\ Q(x,y,d,1) & \dots & \dots & Q(x,y,d,d) \end{pmatrix} \quad (10)$$

$Q_{x,y}$ 'nin simetrik bir matris olduğu ve $d + (d^2 + d) / 2$ geçişlerinin hem P hem de Q'yu hesaplamak için yeterli olduğu görülmektedir. İntegral resimleri oluşturma karmaşıklığı $O(d^2WH)$ olarak ifade edilebilir.

$R(x', y'; x'', y'')$ dikdörtgen bölge olsun; buradaki (x', y') sol üst koordinattır ve (x'', y'') , Aşağıdaki Şekil 1'de gösterildiği gibi sağ alt koordinattır ve $(1, 1)$ ile (x', y') arasında sınırlandırılmıştır.


$$C_{R(1,1;x',y')} = \frac{1}{n-1} [Q_{x',y'} - \frac{1}{n} P_{x',y'} P_{x',y'}^T] \quad (11)$$

Burada $n = x' \cdot y'$ ve benzer şekilde birkaç işlemden sonra, $R(x', y'; x'', y'')$ bölgesinin kovaryansı aşağıdaki gibi hesaplanabilir:

$$C_{R(x',y';x'',y'')} = \frac{1}{n-1} [Q_{x',y'} + Q_{x'',y''} - Q_{x',y''} - Q_{x'',y'} - \frac{1}{n} (P_{x'',y''} + P_{x',y''} -$$

$$P_{x',y''} + P_{x'',y'} - P_{x',y''} + P_{x'',y'})^T] \quad (12)$$

Buradaki $n = (x'' - x') \cdot (y'' - y')$ ifade etmektedir. Bu nedenle, integral resimler oluşturulduktan sonra, herhangi bir dikdörtgen bölgenin kovaryansı $O(d^2)$ zamanında hesaplanabilir.



Şekil 1. İntegral görüntü ifadesi. $R(x', y'; x'', y'')$ dikdörtgenleri, görüntüdeki sol üst (x', y') ve sağ alt (x'', y'') köşelerle tanımlanır ve her nokta bir d boyutlu vektördür.


2.2. Nesne Algılama

Resim içinde bulunan bir nesnenin tespitinde amaç, nesneyi rastgele bir görüntüde konumlandırmak ve düzgün olmayan bir dönüşümden sonra poz oluşturmaktır. Bu durumda piksel konumları (x, y) , renk (RGB) değerleri ile x ve y 'ye göre yoğunlukların birinci ve ikinci dereceden türevlerin normu kullanılmaktadır. Görüntünün her pikseli aşağıda gösterilen dokuz boyutlu bir özellik vektörüne dönüştürülür.

$$F(x,y) = \begin{bmatrix} x & y & R(x,y) & G(x,y) & B(x,y) \\ \left| \frac{dI(x,y)}{dx} \right| & \left| \frac{dI(x,y)}{dy} \right| & \left| \frac{d^2I(x,y)}{dx^2} \right| & \left| \frac{d^2I(x,y)}{dy^2} \right| \end{bmatrix}^T \quad (13)$$

Burada R, G, B , RGB renk değerleridir ve I da yoğunluğu ifade etmektedir. Görüntü türevleri, $[-1 \ 0 \ 1]^T$ ve $[-1 \ 2 \ -1]^T$ filtreleri ile hesaplanır.

Bir bölgenin kovaryansı 9×9 'luk bir matristir. Her ne kadar piksel konumlarının (x, y) varyansı aynı büyüklükteki tüm bölgeler için aynı olsa da kovaryans matrisinin diyagonal olmayan girişlerinde diğer özelliklerle korelasyonları kullanıldığından önem arz etmektedir.



Şekil 2. Nesne gösterimi. Bir nesne özelliği

1 görüntüsünün üst üste gelen bölgelerinden beş kovaryans
2 matrisi oluşturulması. Kovaryanslar nesne tanımlayıcıları
3 olarak kullanılmaktadır.

4 Şekil 2'de, nesne bölgesi içinde hesaplanan resim
5 özelliklerinin beş kovaryans matrisine sahip bir nesneyi
6 temsil ettiği ifade edilmektedir. Başlangıçta tüm resim
7 üzerinde (C1), kaynak görüntüden elde edilen kovaryans
8 hesaplanmaktadır. Hedef resim daha sonra benzer
9 kovaryans matrisine sahip bir bölge içinde araştırılır ve
10 farklılıklar ölçülür. Hedef görüntüdeki tüm konumlarda,
11 eşleşen bölgeleri bulmak için dört büyük dört küçük, dokuz
12 farklı ölçekte analiz gerçekleştirir. Bu çalışmada rasgele bir
13 bölgenin kovaryansını çok hızlı bir şekilde
14 hesaplanabildiği için kaba kuvvet araştırması yapılmıştır.
15 Bu çalışmada hedef resmi ölçeklendirmek yerine, arama
16 penceresinin boyutu değiştirilmiştir. Burada iki ardışık
17 ölçek arasında %15'lik bir ölçeklendirme faktörü
18 bulunmaktadır. x ve y bileşenlerinin varyansı, farklı
19 büyüklükteki bölgeler için aynı değildir ve bu özelliklere
20 karşılık gelen satır ve sütunlar normalleştirilmelidir. Bu
21 durumda pencerenin en küçük boyutunda, iki arama
22 konumu arasında yatay veya dikey olarak üç piksel atlanır.
23 Daha büyük pencereler için her ölçek %15 daha fazla
24 atlanarak bir sonraki tamsayıya yuvarlama işlemi
25 gerçekleştirilir.

26 En iyi eşleşen 1000 konum ve ölçek tutulur. İkinci
27 aşamada, kovaryans matrisleri ($C_i = 1 \dots 5$) kullanarak tespit
28 edilen 1000 konum için arama işlemi tekrarlanır. Bu
29 adımdan sonra nesne modelinin ve hedef bölgenin
30 farklılığı hesaplanır.

$$31 \quad 32 p(O,T) = \min_j \sum_{i=1}^5 p(C_i^O, C_i^T) - p(C_j^O, C_j^T) \quad (14)$$

33
34 C_i^O ve C_i^T 'nin sırasıyla nesne ve hedef
35 kovaryanslarıdır. En az eşleşen 5 bölge kovaryansı bu
36 durumda yok sayılır ve güçlülük artmış olur.

37 2.3. Doku Sınıflandırma

38 Şu anda, doku sınıflandırması için en başarılı yöntem,
39 girişten türetilen bir özellik alanındaki küme merkezi olan
40 textondur. Özellik alanı, her piksele uygulanan bir filtre
41 bankasının çıktısından oluşturulur ve yöntemler yalnızca
42 kullanılan filtre bankasında değişmektedir.

43 Önceki çalışmalarda:

44 - LM: Leung ve Malik tarafından 48 anizotropik ve
45 izotropik filtrenin bir kombinasyonu kullanılmıştır.
46 Özellik alanı 48 boyutludur [10].

47 - S: Schmid tarafından 13 adet dairesel simetrik filtre
48 seti kullanılmıştır. Özellik alanı 13 boyutludur [11].

49 - M4, M8: Her iki sunum Varma ve Zissermann
50 tarafından önerilmiştir [12].

51 Orijinal filtreler hem dairesel olarak simetrik hem de
52 yönlendirilmiş filtreler içermektedir. Ancak özellik
53 vektörüne yalnızca maksimum yanıt odaklı filtreler dahil
54 edilmektedir. Özellik alanı sırasıyla 4 ve 8 boyutludur [13].

55

56 2.3.1 Doku Sınıflandırması İçin Rastgele Kovaryans

57

58 Bu çalışmada doku kullanılmadan sınıflandırma
59 problemine yeni bir yaklaşım sunulmuştur. Öncelikle her
60 pikselden birkaç özellik çıkarılmıştır. Doku sınıflandırma
61 problemi için; hem x hem de y yönünde birinci ve ikinci
62 dereceden yoğunluk türevlerine ait görüntü yoğunlukları
63 ve normları kullanılmıştır. Her piksel, $d = 5$ boyutlu bir
64 özellik alanıyla eşleştirilir.

65

$$66 F(x,y) = \left[I(x,y) \left| \frac{dI(x,y)}{dx} \right| \left| \frac{dI(x,y)}{dy} \right| \left| \frac{d^2I(x,y)}{dx^2} \right| \left| \frac{d^2I(x,y)}{dy^2} \right| \right]^T \quad (15)$$

67


68

69 Her resimden 16×16 ve 128×128 arasında rastgele
70 kare bölgeleri, rasgele boyutlarla örneklenir. İntegral
71 resimleri kullanarak, her bölgenin kovaryans matrisi
72 hesaplanır.

73 Daha sonra her doku görüntüsü s kovaryans matrisleri
74 ile ifade edilir ve her bir doku sınıfından u eğitim doku
75 görüntüleri çıkarılır. Toplam $s \cdot u$ kovaryans matrisi.

76 Doku temsil işlemi, Şekil 3'te gösterilmektedir.

77



78

79 Şekil 3. Doku gösterimi. Her doku sınıfı için u
80 görüntülerinin örneklenmesi ve kovaryans matrislerinin C
81 hesaplanması.

82

83 c texture sınıfları için işlemi tekrarlanır ve her doku
84 sınıfı için aynı işlemler gerçekleşir. Bir test görüntüsü
85 verildiğinde, rastgele seçilen bölgelerden yine kovaryans
86 matrisleri çıkarılır. Her kovaryans matrisi için, eğitim
87 setinin tüm matrislerine olan mesafe ölçülür ve etiket, en
88 yakın olanların (kNN algoritması) oylarının çoğunluğuna
89 göre tahmin edilmektedir.

90

91

92

93

94

95

96

97

98

99

100

101

102

103

104

105

106

107

108

109

110

111

112

113

114

115

116

117

118

119

120

121

122

123

124

125

126

127

128

129

130

131

132

133

134

135

136

137

138

139

140

141

142

143

144

145

146

147

148

149

150

151

152

153

154

155

156

157

158

159

160

161

162

163

164

165

166

167

168

169

170

171

172

173

174

175

176

177

178

179

180

181

182

183

184

185

186

187

188

189

190

191

192

193

194

195

196

197

198

199

200

201

202

203

204

205

206

207

208

209

210

211

212

213

214

215

216

217

218

219

220

221

222

223

224

225

226

227

228

229

230

231

232

233

234

235

236

237

238

239

240

241

242

243

244

245

246

247

248

249

250

251

252

253

254

255

256

257

258

259

260

261

262

263

264

265

266

267

268

269

270

271

272

273

274

275

276

277

278

279

280

281

282

283

284

285

286

287

288

289

290

291

292

293

294

295

296

297

298

299

300

301

302

303

304

305

306

307

308

309

310

311

312

313

314

315

316

317

318

319

320

321



Şekil 4. Nesne algılama (a) Giriş bölgeleri. (b) Kovaryans özellikleri ile bulunan bölgeler. (c) Histogram özellikleriyle bulunan bölgeler.

Şekilde görüldüğü gibi olası tıkanmalara ve büyük aydınlatma değişikliklerine karşı güçlülük (Robustness) artırır. Bu durumda en küçük farklılığa sahip bölge, eşleşen bölge olarak seçilir.

Bu çalışmada şekildeki gibi çeşitli örnekler için eşleştirme sonuçları sunulmuştur ve sonuçlar histogram özellikleriyle karşılaştırılmıştır. Histogram özellikleri hem RGB hem de HSV renk uzayları ile test edilmiştir.

Kovaryans özellikleri tüm hedef bölgelere tam olarak uymaktadır. Oysa histogramda bulunan bölgelerin çoğu hatalıdır. Her iki yöntemle de doğru tespit edilen bölgeler arasında bile, kovaryans özelliklerinin hedefi daha iyi konumlandığı görülmektedir. Mevcut örnek resimlerde tespit işlemi oldukça zordur. Çünkü mevcut resimlerde büyük ölçek, oryantasyon ve aydınlatma değişimleri bulunmaktadır ve hedeflerin bazıları kapalı ve rijit olmayan harekete sahiptir. Bu çalışmada önerilen yaklaşım, neredeyse mükemmel sonuçlar üretmiştir. Ayrıca yüzleri eşleştirme örneklerinde görüldüğü gibi benzer nesnelerin varlığında doğru hedefi eşleştirebildiklerinden kovaryansların, çok ayırt edici oldukları sonucuna varılır.

Doku sınıflandırmada testler 112 dokudan oluşan Brodatz doku veritabanı üzerinde gerçekleştirilmiştir. Veritabanındaki homojen olmayan dokular nedeniyle, sınıflandırma zorlu bir iştir [14]. Bu durumda test ortamı çoğaltılır. Her 640×640 doku görüntüsü dört adet 320×320 alt resme ayrılır ve resimlerin yarısı eğitim, yarısı test için kullanılır. Sonuçların diğer yöntemlerle karşılaştırılması Tablo 1'de ifade edilmiştir. Burada k-ortalama tabanlı kümeleme algoritması (K-Means) için sonuçlar sunulmuştur. Texton histogramları ile doku gösterimi 560 kutudan oluşmaktadır. Sonuçlar, kullanılan filtre sırasına bağlı olarak % 85,71 ile % 3997,32 arasında değişmektedir.


40

Tablo 1. Brodatz veritabanı için sınıflandırma sonuçları

42

	M4	M8	S	LM	Random Cov.
Perform	85.71	94.64	93.30	97.32	97.77

Bu çalışmada test ve eğitim için her resimden $s = 100$ adet rastgele kovaryans örneklenmiştir ve kNN algoritması için $k = 5$ olarak kullanılmıştır. $d = 5$ boyut özellikleri için 46 kovaryans matrisi 5×5 'tir ve daha önce 560 kutuya kıyasla sadece 15 farklı değere sahiptir. Sonuçlar, önceki sonuçların hepsinden daha iyi ve daha hızlıdır (%97,77). 224 resimden sadece 5 resim yanlış sınıflandırılmıştır. Şekil 5'te yanlış sınıflandırılmış görüntülerden ikisi yer almaktadır ve yanlış sınıflandırma genellikle homojen olmayan dokularda görülmektedir.



53

Şekil 5. Yanlış sınıflandırılmış örnekler. (a) Test örnekleri. (b) Aynı sınıftan örnekler. (c) Tahmini doku sınıfından örnekler.

57

Yöntemi rotasyonel olarak değişmez yapmak için gradyan ve Laplacian'ın yoğunluğu ve büyüklüğü kullanılmıştır. Kovaryans matrisleri 3×3 'tür ve sadece 6 farklı değere sahiptir. Bu çok basit özelliklerle bile, sınıflandırma performansı % 94,20'dir. Bu da Tablo 1 de listelenen diğer dönme açısından değişmeyen yöntemlerden (M4, M8, S) daha iyidir. Rastgele büyüklükteki pencere seçimi nedeniyle mevcut yöntemde üretilen sonuç değişmemektedir. Mevcut yaklaşım

1tamamen aydınlatma içermese de, doğrudan özelliklerin
2(yoğunluk ve gradyanlar) kullanılmasından daha güçlü bir
3sonuç üretmektedir. Resimler üzerinde bulunan belirli
4bölgelerdeki yoğunluk ve gradyan değişimleri, aydınlatma
5varyasyonlarında yoğunluktan ve gradyanlardan daha az
6değişmektedir.

7 Bu çalışmada gerçekleştirilen ikinci test bünyesinde
8kovaryans özellikleri diğer olası seçeneklerle
9karşılaştırılmıştır. Önerilen doku sınıflandırma algoritması,
10ham yoğunluk değerleri ve rastgele bölgelerden çıkarılan
11histogramlarla çalıştırılmıştır.

12 Ham yoğunluklar için, rastgele bölgelerin hepsi 16x16
13kare bölgeye normalize edilmiştir. kNN sınıflandırması ile
14mesafeleri hesaplamak için Öklid mesafesi kullanılmıştır
15[15]. Özellik alanı 256 boyutludur. Ham yoğunluk
16değerleri çok gürültülüdür, bu durumda her resimde ki $s = 17500$
17bölgeleri örneklenmiştir.

18 Histogram özelliklerini kullanarak iki test
19gerçekleştirilmiştir. Sadece yoğunluk, birinci - ikinci
20dereceden türevlerin yoğunluğu ve normları incelenmiştir.
21Her iki durumda da benzerlik Bhattacharyya mesafesi ile
22ölçülmüştür [16]. Sadece yoğunluk için 256 kutu,
23türevlerin yoğunluğu ve normları için $5 \times 64 = 320$ kutu
24kullanılmıştır. Hesaplama ve hafıza gereksinimi nedeniyle
25türev histogramlarının ortak yoğunluğunu ve normunu
26oluşturmak pratik değildir.

27 Her doku resminden $s = 100$ bölge örneklendirilmiştir.
28Sonuçlar Tablo 2’de gösterilmiştir. Kovaryansa yakın tek
29sonuç, 320 boyut yoğunluğu ve türev histogramlarının
30birlikte kullanılmasıdır. Çünkü kovaryans özellikleri,
31yoğunluğun ve türevlerin ortak dağılımının
32kovaryanslarıdır. Ancak mevcut kovaryans özellikleri ile
33daha hızlı bir şekilde daha iyi bir performans elde
34edilmiştir.

35

36 **Tablo 2.** Farklı özellikler için sınıflandırma sonuçları

37

	Raw Int.	Int. Hist.	Deriv.Hist.	Covariance
Performans	26.79	83.35	96.88	97.77

38

39

40 **4. Sonuçlar**

41

42 Bu çalışmada nesne tespiti ve doku sınıflandırması
43için kovaryans özellikleri ve ilgili algoritmalar sunulmuştur.
44Kovaryans özelliklerinin ve algoritmalarının üstün
45performansında tümlev imge gösterim yöntemi olduğu,
46önceki tekniklerle ve özelliklerle detaylı olarak
47karşılaştırılarak birkaç örnekte gösterilmiştir.

48

49 **Teşekkür**

50

51 Bu çalışmada bana yardımcı olan değerli hocam

52Dr.Öğr.Üyesi Orhan AKBULUT’ a teşekkürü borç bilirim.

53

54 **Kaynaklar**

55[1] Rosenfeld A., Vanderburg G. J., 1977. Coarse-
56 Fine Template Matching. IEEE Transactions on
57 Systems, Man, and Cybernetics **7**, 104-107.

58

59[2] Ros B. R., Poggio T., 1993. Face recognition:
60 Features versus templates. IEEE Trans.Pattern Anal.
61 Machine Intell **15**, 1042 – 1052.

62

63[3] Turk M.A., Pentland A.P.,1991. Face recognition
64 using eigenfaces. IEEE Computer Society Conference
65 on Computer Vision and Pattern Recognition, pp.586–
66 591.

67

68[4] Viola P., Jones M.,2001. Rapid object detecti on
69 using a boosted cascade of simple features. In: Proc.
70 IEEE Conf. on Computer Vision and Pattern
71 Recognition, Kauai, HI,8-14 December, Volume 1.
72 pp.511–518.

73

74[5] Förstner W., Moonen B.,1999. A metric for covariance
75 matrices. Technical report,Dept. of Geodesy and
76 Geoinformatics Universität Bonn Nussallee **15**,113-
77 114.

78

79[6] Förstner W., Moonen B.,1999. A metric for covariance
80 matrices. Technical report,Dept. of Geodesy and
81 Geoinformatics Universität Bonn Nussallee **15**,115-
82 116.

83

84[7] Viola P., Jones M.,2001. Rapid object detecti on
85 using a boosted cascade of simple features. In: Proc.
86 IEEE Conf. on Computer Vision and Pattern
87 Recognition, Kauai, HI, 8-14 December, Volume 1.
88 pp.511–518.

89

90[8] Porikli F.,2005 Integral histogram: A fast way to
91 extract histograms in cartesian spaces.In: Proc. IEEE
92 Conf. on Computer Vision and Pattern Recognition,
93 San Diego,CA. Volume 1,pp.829 – 836.

94

95[9] Viola P., Jones M.,2001. Rapid object detection using
96 a boosted cascade of simple features. In: Proc. IEEE
97 Conf. on Computer Vision and Pattern Recognition,
98 Kauai, HI, 8-14 December, Volume 1. pp.511–518.

99

100[10] Leung T., Malik J.,2001. Representing and
101 recognizing the visual appearance of materials using
102 three-dimensional textons. Intl. J. of Comp. Vision
103 **43**,29–44.

104

105[11] Schmid C.,2001. Constructing models for content-
106 based image retrieval. In: Proc. IEEE Conf. on
107 Computer Vision and Pattern Recognition, Kauai, HI,
108 8-14 December, pp.39–45.

109

- 1[12] Varma M., Zisserman A.,2002. Statistical approaches 23 In:Proc. IEEE Conf. on Computer Vision and Pattern
2 to material classification. In: Proc. European Conf. on 24 Recognition, Hilton Head, SC,June 15-15 Volume 1,
3 Computer Vision, Copehagen, Denmark,pp.255-271. 25 pp.142–149.
4 26
- 5[13] Georgescu B., Shimshoni I., Meer P.,2003. Mean shift 27
6 based clustering in high dimensions. A texture 28
7 classification example. In: Proc. 9th Intl. Conf. on 29
8 Computer Vision, Nice, France,pp.456–463. 30
9 31
- 10[14] Georgescu B., Shimshoni I., Meer P.,2003. Mean shift 32
11 based clustering in high dimensions. A texture 33
12 classification example. In: Proc. 9th Intl. Conf. on 34
13 Computer Vision, Nice, France,pp.456–463. 35
14 36
- 15[15] Mar'ee R., Geurts P., Piater J., Wehenkel L.,2005. 37
16 Random subwindows for robust image classification. 38
17 In: Proc. IEEE Conf. on Computer Vision and Pattern 39
18 Recognition, San Diego, CA,Agust 12-12. Volume 40
19 1,pp.34–40. 41
20 42
- 21 [16] Comaniciu D., Ramesh V., Meer P.,2000. Real-
22 time tracking of non-rigid objects using mean shift.
43